

Guia 1

FACULDADE DE TECNOLOGIA PADRE DANILO DE OLIVEIRA OHL

**CAIO BANDEIRA DE FRANÇA
EDUARDO RIBEIRO PIMENTA
HEBERT ROCHA LIMA DA SILVA
ITALO SAMPAIO DE LUCENA**

**APLICAÇÃO DE ALGORITMOS DE MACHINE LEARNING PARA ANÁLISE
PREDITIVA VISANDO A MELHORIA DA GESTÃO DE ESTOQUE EM
RESTAURANTES DE PEQUENO PORTE**

BARUERI

2026

FACULDADE DE TECNOLOGIA PADRE DANILO DE OLIVEIRA OHL

CAIO BANDEIRA DE FRANÇA

EDUARDO RIBEIRO PIMENTA

HEBERT ROCHA LIMA DA SILVA

ITALO SAMPAIO DE LUCENA

**APLICAÇÃO DE ALGORITMOS DE MACHINE LEARNING PARA ANÁLISE
PREDITIVA VISANDO A MELHORIA DA GESTÃO DE ESTOQUE EM
RESTAURANTES DE PEQUENO PORTE**

Projeto de pesquisa apresentado à banca examinadora da Faculdade de Tecnologia de Barueri como requisito parcial para obtenção do título de tecnólogo em Gestão da Tecnologia da Informação.

Orientador Prof. Vander Ribeiro Elme

BARUERI

2026

SUMÁRIO

1 INTRODUÇÃO	3
2 OBJETIVOS.....	5
2.1 Objetivo geral	5
2.2 Objetivos específicos	5
3 JUSTIFICATIVA.....	6
4 REFERENCIAL TEÓRICO.....	7
4.1 Gestão operacional em restaurantes de pequeno porte	7
4.1.1 Modelagem de processos com BPMN.....	7
4.2 Gestão de estoque.....	10
4.3 Machine learning e inteligência artificial	11
4.3.1 Modelo baseado em regressão linear e regularização	12
5 METODOLOGIA	13
5.1 Classificação e fundamentação da pesquisa	13
5.2 Procedimento de Pesquisa Aplicada	13
5.3 Delimitação da pesquisa	13
5.4 Diagnóstico operacional.....	14
5.5 Coleta de dados	14
5.6 Resultados dos questionários	15
5.7 Ferramentas e algoritmos	16
5.8 Métricas de Avaliação e Análise Estatística	17
5.9 Plano de análise de resultados	17
6 CRONOGRAMA	18
REFERÊNCIAS.....	20

1 INTRODUÇÃO

O setor de restaurantes e similares desempenha um papel relevante na economia brasileira, destacando-se pela expressiva presença de micro e pequenas empresas. Dados do Observatório Setorial Territorial do Sebrae ([s.d.]), com base em informações da Receita Federal, indicam que o segmento registrou uma taxa de criação de novos negócios de 49,4% em 2025. Além disso, até fevereiro de 2026, mais de 428 mil estabelecimentos encontravam-se ativos no país, sendo a maior parte composta por microempresas (ME) e microempreendedores individuais (MEI), evidenciando a importância econômica e social da atividade, especialmente no que se refere à geração de emprego, renda e desenvolvimento local.

Apesar do crescimento do setor, restaurantes de pequeno porte passam por diversos desafios relacionados à gestão do negócio, sendo essas as dificuldades no controle de estoque, alta concorrência, qualidade constante, logística eficiente e a manutenção do fluxo de caixa (VIANA, 2024). A gestão de estoques desempenha um papel fundamental no equilíbrio entre oferta e demanda, contribuindo para a disponibilidade de produtos e para a redução de custos operacionais. A falta de estoque pode comprometer o atendimento ao cliente, enquanto o excesso representa capital imobilizado e aumenta o risco de perdas, especialmente em produtos perecíveis. Dessa forma, a capacidade de prever a demanda torna-se um fator essencial para o gerenciamento eficiente dos estoques e para a tomada de decisões organizacionais (SLACK; BRANDON-JONES; JOHNSTON, 2018).

Tendo em vista o avanço da transformação digital, empresas de diferentes setores passaram a adotar tecnologias capazes de auxiliar na gestão e na tomada de decisões. Nesse contexto, uma das tecnologias que se destaca é o *Machine Learning* (aprendizado de máquina ou ML), uma área da Inteligência Artificial que utiliza algoritmos para analisar dados, identificar padrões e realizar previsões com base em informações históricas (BERGMANN, [s.d.]). Diante desse cenário, surge o seguinte questionamento: “Em que medida modelos de *Machine Learning* podem contribuir para a previsão da demanda e para a melhoria da gestão de estoque em restaurantes de pequeno porte?”.

Com o propósito de responder a essa questão, este projeto propõe investigar a aplicação de ML como ferramenta de apoio à gestão de estoque em restaurantes de pequeno porte. Pretende-se analisar de que forma a utilização de dados operacionais

pode contribuir para a previsão da demanda e para a redução de desperdícios associados ao gerenciamento de insumos. Para tanto, o desenvolvimento do projeto contemplará aspectos como os modelos a serem avaliados, os dados a serem coletados, a pesquisa de campo, os critérios de avaliação dos resultados e a viabilidade de implementação.

2 OBJETIVOS

2.1 Objetivo geral

Propor e avaliar a aplicação de um modelo preditivo baseado em algoritmos de *Machine Learning* (Regressão Linear) como ferramenta de suporte à decisão na previsão de demanda e gestão de estoque a fim de ajudar restaurantes de pequeno porte.

2.2 Objetivos específicos

- a) Identificar e examinar os conceitos fundamentais associados à administração de estoques, previsão de demanda e *Machine Learning*;
- b) Mapear os requisitos e os desafios de coleta de dados e fatores operacionais em restaurantes de pequeno porte por via de pesquisa de campo;
- c) Desenvolver e treinar modelo de *Machine Learning* (Regressão Linear Múltipla) utilizando dados baseados em no fluxo de estoque e variáveis externas (ex: sazonalidade, feriados);
- d) Analisar o desempenho do modelo utilizando métricas de precisão e examinando os resultados alcançados.

3 JUSTIFICATIVA

O crescimento expressivo do setor de alimentação no Brasil, aliado às altas taxas de mortalidade de micro e pequenas empresas, evidencia a necessidade de estudos voltados à melhoria da gestão operacional desses estabelecimentos. De acordo com o relatório técnico feito pelo SEBRAE ([s.d.]), ao final de cinco anos, 52,3% dos pequenos negócios encerram suas atividades, sendo MEI os mais vulneráveis, com taxa de não sobrevivência de cerca de 59% no mesmo período. Nessa mesma linha, o relatório técnico de sobrevivência da instituição aponta que, enquanto 40% dos MEI abrem o negócio por necessidade, 50,9% das MPE surgem ao identificar uma oportunidade de mercado, o que reflete perfis distintos de resiliência e planejamento empresarial (SEBRAE, 2025).

Nesse contexto, a gestão de estoques representa um dos principais gargalos enfrentados por pequenas empresas, cuja maior parcela é composta por restaurantes de pequeno porte, uma vez que a ausência de controle adequado contribui diretamente para o aumento de custos, o desperdício ou falta de insumos e a redução de competitividade, levando a clientes insatisfeitos (SLACK; BRANDON-JONES; JOHNSTON, 2018).

Do ponto de vista de relevância social, pequenos restaurantes desempenham papel significativo na geração de emprego e renda, especialmente em comunidades locais. A ineficiência na gestão de recursos impacta não apenas a sustentabilidade financeira do negócio, mas também os trabalhadores e fornecedores que dele dependem. Dessa forma, investigar soluções acessíveis e aplicáveis a esse perfil de estabelecimento representa uma contribuição direta ao fortalecimento da atividade econômica local.

Do ponto de vista teórico e prático, a aplicação de ML à previsão de demanda apresenta potencial para transformar a forma como pequenos negócios gerenciam seus recursos. O uso de dados históricos operacionais para identificar padrões de consumo e antecipar variações de demanda pode contribuir para decisões mais assertivas sobre compras e reposição de estoque, reduzindo tanto o risco de desabastecimento quanto o excesso de produtos perecíveis (BERGMANN, [s.d.]; SLACK; BRANDON-JONES; JOHNSTON, 2018). Assim, este projeto pretende contribuir para a ampliação do conhecimento nessa área, oferecendo uma abordagem metodológica replicável para contextos similares.

4 REFERENCIAL TEÓRICO

4.1 Gestão operacional em restaurantes de pequeno porte


Segundo Slack et al. (2018), a gestão operacional envolve o planejamento, organização e controle dos processos produtivos, visando garantir eficiência e qualidade na entrega de produtos e serviços. Esse processo abrange desde o recebimento de insumos até a finalização dos pedidos, incluindo o controle de estoque, o fluxo produtivo e a alocação de recursos.

Em restaurantes de pequeno porte, a gestão operacional apresenta desafios específicos, como a variação da demanda ao longo do tempo, a limitação de recursos e a necessidade de respostas rápidas às mudanças no volume de pedidos (VIANA, 2024). Segundo Slack et al. (2018), a eficiência operacional está diretamente associada à capacidade de coordenar recursos produtivos de forma alinhada à demanda, reduzindo falhas no atendimento e melhorando o desempenho do sistema.

Diante desse contexto, torna-se fundamental a adoção de práticas que permitam maior previsibilidade das operações. Nesse sentido, abordagens baseadas em análise preditiva e algoritmos de *Machine Learning* surgem como alternativas capazes de antecipar variações na demanda e subsidiar decisões mais precisas sobre o planejamento operacional e o controle de insumos (JAMES et al., 2021).

4.1.1 Modelagem de processos com BPMN

A modelagem de processos de negócio foi realizada por meio da notação BPMN (*Business Process Model and Notation*), com o objetivo de representar de forma estruturada e padronizada o fluxo operacional de um restaurante de pequeno porte, desde o planejamento de compras até a finalização da venda ao cliente. De acordo com Dumas et al. (2018), a BPMN é uma notação amplamente utilizada para descrever processos organizacionais, permitindo a visualização clara das atividades, eventos, decisões e fluxos de informação envolvidos.



Fonte: Do autor (2026)

O modelo desenvolvido contempla diferentes áreas operacionais do restaurante, organizadas em *swimlanes*, incluindo fornecedor, estoque/compras, vendas (PDV), cozinha/produção, cliente e setor financeiro. Essa divisão possibilita identificar de forma clara as responsabilidades de cada setor e a interação entre eles ao longo do processo.

Na raia de fornecedor, o processo inicia-se com a identificação da necessidade de compra por parte do restaurante. A partir disso, o fornecedor recebe o pedido de compra, realiza a separação dos produtos e efetua o envio das mercadorias. Essa etapa representa a origem do fluxo de suprimentos que abastece o sistema.

Na raia de estoque e compras, o processo tem início com a análise da demanda e do histórico de vendas, que subsidia o planejamento de compras. Com base nessa análise, é gerado o pedido de compra, que é encaminhado ao fornecedor. Após o recebimento da mercadoria, ocorre a conferência dos produtos, verificando quantidade, qualidade, validade e conformidade com a nota fiscal. Caso haja inconsistências, a mercadoria é recusada e o fornecedor é comunicado. Quando os produtos estão conformes, eles são armazenados no estoque seguindo o método FIFO (*First In, First Out*) e o sistema realiza a atualização das entradas.

Paralelamente, o estoque é constantemente monitorado, permitindo verificar se os níveis são suficientes ou se há necessidade de reposição.

Na raia de vendas (PDV), o processo inicia-se quando o cliente realiza um pedido. Esse pedido é registrado no sistema de ponto de venda, gerando informações como itens solicitados, quantidades e observações. Esses dados são então encaminhados para a cozinha, permitindo o início da produção. Essa etapa representa a interface direta entre cliente e operação.

Na raia de cozinha e produção, o pedido recebido é preparado conforme padrões previamente definidos. Durante esse processo, ocorre a baixa automática dos itens utilizados no estoque, garantindo que as saídas sejam registradas de forma integrada ao sistema. Após o preparo, o pedido é finalizado e encaminhado para entrega ao cliente.

Na raia do cliente, o fluxo contempla a recepção do pedido finalizado e a realização do pagamento, que pode ocorrer por diferentes meios, como dinheiro, cartão ou pagamento digital. Essa etapa marca a conclusão da interação principal com o cliente.

Na raia financeira, as informações de pagamento são registradas e conciliadas, atualizando as contas a receber. Em seguida, são gerados relatórios financeiros que permitem o acompanhamento do desempenho econômico do restaurante. Esses dados são integrados a um banco de dados central, que também armazena informações operacionais de estoque, vendas e produção.

Por fim, o processo contempla um ciclo contínuo de retroalimentação, no qual os dados consolidados são utilizados para gerar relatórios gerenciais e apoiar o planejamento de demanda e operações futuras. Essa integração evidencia a importância da utilização de dados ao longo de todo o fluxo, permitindo maior controle e suporte à tomada de decisão.

O modelo apresentado representa o processo atual (*As-Is*) das operações de um restaurante de pequeno porte, evidenciando como as atividades são executadas no cenário real, sem a aplicação de técnicas avançadas de análise preditiva. Essa representação permite compreender o funcionamento do sistema como um todo, identificar pontos críticos e estabelecer uma base estruturada para futuras melhorias, como a integração de modelos de *machine learning* voltados à previsão de demanda.

Dessa forma, a modelagem em BPMN não apenas representa o fluxo operacional do restaurante, mas também evidencia a interdependência entre as áreas

e a importância da organização dos processos, mesmo em ambientes com estrutura enxuta, como é o caso de restaurantes de pequeno porte.

4.2 Gestão de estoque

Segundo Slack et al. (2018), a gestão de estoque compreende o conjunto de práticas relacionadas ao planejamento, controle e monitoramento dos materiais armazenados em uma organização, com o objetivo de garantir a disponibilidade adequada de insumos e manter o equilíbrio entre oferta e demanda. No contexto de restaurantes de pequeno porte, essa atividade assume papel estratégico, uma vez que está diretamente relacionada ao volume de pedidos e à necessidade de reposição eficiente dos insumos utilizados na produção.

É dito pelo autor também que, a gestão eficiente de estoques busca alinhar os níveis de suprimentos às necessidades operacionais, evitando tanto a indisponibilidade de produtos quanto o acúmulo excessivo. Esse equilíbrio impacta diretamente o desempenho do sistema produtivo, influenciando o planejamento de compras, a organização da produção e o atendimento ao cliente.

Nesse cenário, a previsão de demanda torna-se um elemento essencial para orientar a reposição de insumos e o dimensionamento dos estoques, permitindo maior precisão no planejamento e maior controle sobre os recursos disponíveis.

4.3 *Machine learning* e inteligência artificial

Embora os termos Inteligência Artificial (IA) e *Machine Learning* (ML) sejam frequentemente utilizados como sinônimos, eles designam conceitos de escopo distinto. Segundo Bergmann (2020), a IA constitui um campo amplo de tecnologias capazes de simular funções cognitivas associadas à inteligência humana, tais como percepção visual, compreensão de linguagem, análise de informações e tomada de decisão. O ML, por sua vez, representa um subconjunto da IA que capacita sistemas a aprenderem e aprimorarem seu desempenho de forma autônoma, por meio de algoritmos que analisam grandes volumes de dados — sendo que quanto maior e mais representativo o conjunto de dados, mais precisos tendem a ser os resultados obtidos (BERGMANN, 2020).

O processo de aprendizado fundamenta-se na lógica matemática, sendo imprescindível que todas as variáveis sejam expressas numericamente. Os dados são estruturados em vetores, permitindo que o algoritmo mapeie correlações e estime saídas desejadas. No contexto de dados operacionais — como o histórico de vendas de um estabelecimento —, variáveis qualitativas e temporais, tais como dias da semana, meses e a ocorrência de feriados, passam por um processo de codificação numérica (*encoding*), de modo que o modelo consiga quantificar o impacto dessas condicionantes sobre o comportamento do consumo (BERGMANN, 2020).

A literatura classifica o aprendizado de máquina em três vertentes principais: aprendizado supervisionado, não supervisionado e aprendizado por reforço (BERGMANN, 2020). No âmbito deste projeto, será abordado exclusivamente o aprendizado supervisionado, que consiste no treinamento de um modelo preditivo a partir de um conjunto de dados históricos rotulados — isto é, dados nos quais a resposta esperada já é previamente conhecida. Esse paradigma se aplica de forma especialmente adequada a tarefas que exigem alto grau de precisão analítica vinculada a respostas históricas concretas, como a previsão do volume de vendas diárias ou a estimativa da quantidade necessária de insumos para os dias subsequentes.

4.3.1 Modelo baseado em regressão linear e regularização

Dentro do ecossistema do aprendizado supervisionado aplicado a problemas de regressão — nos quais o objetivo é prever um valor numérico contínuo —, o presente estudo adota modelos lineares como abordagem central. A Regressão Linear Múltipla funciona como modelo base, buscando uma equação matemática que estabeleça relações lineares entre a variável dependente (a demanda futura por insumos) e múltiplas variáveis preditoras independentes, como o histórico de consumo e os fatores sazonais codificados (HYNDMAN; ATHANASOPOULOS, 2021). Contudo, ao incorporar simultaneamente diversas variáveis operacionais e sazonais, os modelos lineares tradicionais tornam-se suscetíveis ao *overfitting* — fenômeno pelo qual o modelo se ajusta excessivamente aos dados de treinamento e perde capacidade de generalização para dados futuros.

Para contornar essa limitação, a literatura recomenda a aplicação de técnicas de regularização, representadas pelos modelos Ridge e Lasso. O Ridge incorpora uma penalidade matemática que reduz (encolhe) os coeficientes das variáveis, impedindo que fatores isolados exerçam influência desproporcional sobre a previsão final. O Lasso, por sua vez, realiza seleção automática de variáveis, podendo zerar os coeficientes daquelas que se mostrem irrelevantes para o comportamento da demanda — resultando em modelos mais parcimoniosos e interpretáveis. A adoção combinada dessas técnicas reduz a variância do sistema e garante uma ferramenta preditiva leve e adaptada à realidade computacional de pequenos negócios (JAMES et al., 2021).

A validação dos modelos será conduzida por meio de métricas de erro estatístico. Serão adotados o MAE (*Mean Absolute Error*) e o MAPE (*Mean Absolute Percentage Error*). O MAPE, em particular, expressa a divergência entre a demanda real e a prevista em termos percentuais, o que facilita a interpretação gerencial dos resultados e confere maior segurança à tomada de decisões relativas à reposição e ao controle de estoques perecíveis (HYNDMAN; ATHANASOPOULOS, 2021).

5 METODOLOGIA

5.1 Classificação e fundamentação da pesquisa

Esta pesquisa se caracteriza como qualitativa-quantitativa (Mista). A abordagem Qualitativa é fundamental para esse estudo, pois permite compreender as rotinas operacionais cotidianas dos estabelecimentos, a percepção dos gestores e fluxos de processos, que englobam o gerenciamento de restaurantes de pequeno porte em cenários que não são automatizados ou padronizados, a fim de entender a realidade que as empresas se encontram.

A pesquisa Quantitativa se traduz no tratamento matemático de dados e na construção do algoritmo para aprendizagem do *Machine Learning*, este método utilizará coleta de dados para testar hipóteses com base em métricas numéricas e na análise estatística, a junção das ambas as abordagens garantem maior entendimento sobre os eventos.

5.2 Procedimento de Pesquisa Aplicada

O procedimento metodológico adotado é Pesquisa aplicada, combinada com estratégia de Estudo de caso, pois busca desenvolver e avaliar algoritmos de *Machine Learning* voltados a previsão de demanda no controle de estoque, sendo motivada pela necessidade de compreender as particularidades operacionais dos restaurantes participantes, e assim projetar a viabilidade de modelos preditivos sobre dados coletados nesses ambientes.

Como parte da metodologia, foi elaborado o diagrama BPMN (*Business Process Model and Notation*), para mapear os fluxos operacionais, identificar os pontos críticos dos processos de gestão de estoque e demonstrar como a adoção de modelos preditivos pode contribuir futuramente para as decisões operacionais.

5.3 Delimitação da pesquisa

Para atentar à necessidade da pesquisa, foi delimitado estritamente ao nicho de restaurantes de pequeno porte, a amostra selecionada para coleta de dados e

validação de modelos, contemplará 3 estabelecimentos caracterizados como restaurantes próprios e independentes.

O local geográfico da pesquisa restringe-se à Zona Oeste de São Paulo, os participantes serão a fonte primária das informações qualitativas e operacionais, são gerentes ou responsáveis pelos estabelecimentos. Os perfis desses profissionais se caracterizam responsáveis pela saúde financeira do negócio, pelo conhecimento prático das oscilações do local e pela autonomia final para realizar decisões.

5.4 Diagnóstico operacional

Esta fase inicial focou na compreensão das dores da gestão de estoque atual. O principal instrumento utilizado foi um questionário estruturado de diagnóstico operacional, composto por perguntas estratégicas abertas e fechadas voltadas aos gestores dos restaurantes, abordando os seguintes tópicos de investigação:

- Modelo principal do restaurante e tamanho da equipe de trabalho;
- O maior desafio enfrentado atualmente com o estoque;
- Métodos utilizados para estimar a demanda para cada dia da semana;
- Nível de clareza sobre a margem de lucro dos pratos e diferença entre pedidos próprios e *marketplaces* (*iFood*);
- Consolidação de avaliações de clientes e identificação de gargalos operacionais caso o movimento dobrasse;
- Grau de alteração das operações com base em fatores externos (clima, eventos, feriados);
- Impacto mensal visível do desperdício de alimentos no resultado financeiro.

As respostas obtidas evidenciaram uma forte dependência da "experiência e intuição do gestor" para a previsão de demanda e problemas como "falta de insumos em dias de pico" e "ausência de controle estruturado de estoque", evidenciando os gargalos e as falhas de controle causadas pela ausência de ferramentas preditivas.

5.5 Coleta de dados

A coleta de dados operacionais para alimentação dos modelos preditivos abrangerá variáveis diárias: volume de vendas por item do cardápio, quantidade de insumos consumidos, variáveis contextuais como dia da semana, período do mês e

datas festivas. Resultado da pesquisa, o Quadro 1 apresenta o perfil dos três estabelecimentos participantes:

Restaurante	Modelo	Funcionários	Principal desafio com estoque	Estimativa de demanda
Rancho da Mineirinha	Independente	6 a 15	Sem controle estruturado de estoque	Experiência e intuição do gestor
La Rocca	Independente	Até 5	Falta de insumos em dias de pico	Experiência e intuição do gestor
Restaurante B	Independente + Delivery	Mais de 30	Sem dificuldades relevantes declaradas	Produção sob demanda (pedido a pedido)

5.6 Resultados dos questionários

A gestão de estoque, dois dos três estabelecimentos, Rancho da Mineirinha e La Rocca, relataram ausência de controle estruturado, enquanto o Restaurante B declarou não enfrentar dificuldades relevantes, o que se explica pelo modelo de produção sob demanda adotado por esse estabelecimento.

Quanto à estimativa de demanda, todos os três restaurantes utilizam exclusivamente a experiência e a intuição do gestor como base para planejamento, sem qualquer ferramenta formal de previsão. Isso evidencia um gargalo operacional diretamente pela proposta deste trabalho.

O impacto do desperdício foi avaliado em escala de 1 a 5. O Rancho da Mineirinha atribuiu grau 3, indicando impacto moderado e visível; a La Rocca atribuiu grau 4, sinalizando impacto relevante com repercussão mensal no resultado financeiro. O Restaurante B não forneceu essa informação. O Quadro 2 consolida os principais indicadores obtidos:

Restaurantes	Controle de estoque	Estimativa de demanda	Impacto do desperdício	Ferramenta tecnológica usada	Processo que quebraria primeiro
Rancho da Mineirinha	Sem controle estruturado	Intuição do gestor	3	Robô digital / redes sociais	Gestão de pedidos
La Rocca	Sem controle estruturado	Intuição do gestor	4	Planilhas Excel	Gestão de pedidos
Restaurante B	Sem dificuldades relevantes	Produção por pedido	Não informado	Não especificado	Gestão de pedidos / financeiro

Esses resultados reforçam a relevância do trabalho, a ausência de ferramentas preditivas formais nos três estabelecimentos cria uma oportunidade concreta de contribuição prática, tanto para a redução de desperdícios quanto para a melhoria do planejamento operacional.

5.7 Ferramentas e algoritmos

O tratamento e a análise dos dados serão realizados com as seguintes ferramentas:

- Microsoft Excel: organização inicial dos dados coletados e criação de tabelas comparativas.
- Python 3.x: linguagem principal para desenvolvimento, treinamento e avaliação dos modelos preditivos.
- Pandas: manipulação, limpeza e organização dos dados operacionais.
- Scikit-learn: modelagem dos dados, além de ferramentas de validação cruzada e cálculo de métricas.
- Power BI: construção de *dashboards* com indicadores de previsão de demanda, controle de estoque e índices de desperdício.

5.8 Métricas de Avaliação e Análise Estatística

O modelo será avaliado por meio de três métricas matemáticas. O MAE (*Mean Absolute Error*) mede a média dos erros absolutos entre valores previstos e reais. O

RMSE (*Root Mean Squared Error*) penaliza erros maiores de forma mais intensa, sendo especialmente útil para identificar desvios extremos. O R^2 (Coeficiente de Determinação) indica a proporção da variância da demanda explicada pelo modelo, variando de 0 a 1, com valores próximos a 1 indicando maior poder explicativo.

Para validação do modelo, será utilizada a técnica de validação cruzada por janelas temporais (*time series cross-validation*), adequada a dados sequenciais. Para comparação estatística entre os modelos, será aplicado o teste de Diebold-Mariano (1995), verificando se as diferenças de desempenho observadas são estatisticamente significativas.

5.9 Plano de análise de resultados

Os resultados serão analisados sob três pilares: Previsão de Demanda, comparação das previsões geradas pelos três algoritmos com os valores reais observados, identificando o modelo de melhor desempenho para cada restaurante, Controle de Estoque, análise do impacto das previsões sobre o dimensionamento do estoque, medindo a redução de excessos e rupturas com base nos dados coletados, Gráficos Visuais, construção de *dashboards* no Power BI consolidando os principais indicadores operacionais dos três estabelecimentos para suporte à tomada de decisão.

6 CRONOGRAMA

O desenvolvimento desta pesquisa foi planejado para ocorrer entre os meses de agosto e novembro, sendo dividido em quatro etapas principais: levantamento e preparação dos dados, desenvolvimento dos modelos preditivos, análise dos resultados e elaboração do trabalho final.

Na primeira etapa, durante o mês de agosto, será conduzida uma pesquisa de campo junto a estabelecimentos do setor alimentício, com o objetivo de coletar informações relacionadas ao consumo de insumos, desperdícios, sazonalidade da demanda e práticas de gestão de estoque. Paralelamente, será realizada a revisão bibliográfica sobre gestão de estoques, previsão de demanda e técnicas de aprendizado de máquina aplicadas ao contexto da pesquisa. Com base nos dados coletados e na fundamentação teórica, serão definidos os parâmetros necessários para a simulação da base de dados utilizada no estudo. Em seguida, será desenvolvido o algoritmo responsável pela geração do histórico sintético de consumo e pela preparação dos dados, incluindo a aplicação de técnicas de engenharia de atributos para representar fatores temporais e sazonais.

Durante o mês de setembro, será realizada a implementação dos modelos preditivos. Inicialmente, a base de dados será dividida em conjuntos de treinamento e teste, possibilitando o desenvolvimento dos modelos de Regressão Linear e Regressão Ridge. Posteriormente, será implementada a Regressão Lasso, empregada para a seleção automática de variáveis relevantes. Nessa mesma etapa, serão aplicados procedimentos de validação cruzada para ajuste dos hiperparâmetros dos modelos e otimização de seu desempenho.

No mês de outubro, serão conduzidos os experimentos e as avaliações dos modelos desenvolvidos. As previsões serão realizadas sobre os dados de teste e os resultados serão analisados por meio das métricas Erro Absoluto Médio (MAE) e Erro Percentual Absoluto Médio (MAPE). Após a obtenção dos resultados quantitativos, será realizada a análise comparativa dos modelos, acompanhada da elaboração de gráficos e representações visuais que permitam interpretar o comportamento preditivo de cada abordagem.

Por fim, durante o mês de novembro, ocorrerá a consolidação da pesquisa por meio da redação dos capítulos finais do trabalho, incluindo a apresentação e discussão dos resultados obtidos. Também serão realizadas a revisão textual, a

normalização conforme as normas da ABNT e a preparação da versão definitiva da monografia. Na última semana do cronograma, serão desenvolvidos os slides e o material de apoio para a apresentação e defesa do Trabalho de Conclusão de Curso.

Cronograma

Mês	Período (Semanas)	Etapa do TCC / Atividade Acadêmica	Descrição das Atividades de Pesquisa	Entrega Prevista (Artefato)
AGO	Semana 1	Fase 1: Pesquisa de Campo e Fundamentação Inicial	Realização de pesquisa de campo em restaurantes da cidade (entrevistas/questionários) para levantar dados reais sobre consumo, desperdício, sazonalidade, fornecedores e práticas de gestão de estoque.	Relatório da pesquisa de campo com dados coletados e insights iniciais.
	Semanas 2	Fase 1: Fundamentação e Definição dos Parâmetros	Levantamento bibliográfico sobre gestão de estoques, previsão de demanda e desperdício de insumos em restaurantes. Definição dos parâmetros utilizados na simulação dos dados.	Documento com os parâmetros e premissas adotadas.
	Semanas 3 e 4	Fase 1: Simulação e Preparação dos Dados	Desenvolvimento do algoritmo para geração do histórico sintético de consumo de estoque. Tratamento dos dados e aplicação de técnicas de engenharia de atributos relacionadas à sazonalidade e calendário.	Base de dados simulada, tratada e preparada para modelagem.
SET	Semanas 5 e 6	Fase 2: Implementação dos Modelos Preditivos	Divisão da base em conjuntos de treinamento e teste. Implementação dos modelos de Regressão Linear tradicional (OLS) e Regressão Ridge (L2) para previsão de demanda.	Modelos OLS e Ridge treinados e avaliados preliminarmente.
	Semanas 7 e 8	Fase 2: Otimização e Seleção de Variáveis	Implementação da Regressão Lasso (L1) para seleção automática de atributos. Aplicação de validação cruzada para ajuste do parâmetro de regularização α .	Modelo Lasso ajustado e parâmetros otimizados.
OUT	Semanas 9 e 10	Fase 3: Testes e Extração das Métricas de Erro	Execução das previsões na base de teste e cálculo matemático dos erros estatísticos propostos: MAE (Erro Absoluto) e MAPE (Erro Percentual).	Planilha e tabelas de dados com os erros calculados.
	Semanas 11 e 12	Fase 3: Análise de Resultados e Visualização Gráfica	Diagnóstico do comportamento dos modelos perante o overfitting. Plotagem dos gráficos científicos comparando o consumo real versus o previsto para inclusão no texto.	Gráficos e figuras geradas para o corpo do trabalho.
NOV	Semanas 13 e 14	Fase 4: Redação do Relatório Final e Normatização	Redação do capítulo de Resultados e Discussões, conclusão do trabalho, revisão gramatical e formatação de todo o texto segundo as normas da ABNT.	Monografia completa impressa/em PDF para depósito.
	Semana 15	Fase 4: Preparação para a Defesa Acadêmica	Criação do material de apoio visual (slides) sintetizando a metodologia, a matriz de dados estruturada e a comparação do MAPE entre os modelos.	Slides da apresentação de defesa concluídos.

Fonte: Do autor (2026)

REFERÊNCIAS

- BERGMANN, Dave. **O que é aprendizado de máquina?** IBM *Think*, 2020. Disponível em: <https://www.ibm.com/br-pt/think/topics/machine-learning>. Acesso em: 9 jun. 2026.
- DIEBOLD, Francis X.; MARIANO, Roberto S. **Comparing predictive accuracy**. *Journal of Business & Economic Statistics*, v. 13, n. 3, p. 253–263, 1995.
- DUMAS, Marlon; LA ROSA, Marcello; MENDLING, Jan; REIJERS, Hajo A. **Fundamentals of Business Process Management**. 2. ed. Berlin: Springer, 2018.
- HYNDMAN, Rob J.; ATHANASOPOULOS, George. **Forecasting: principles and practice**. 3. ed. Melbourne: OTexts, 2021. Disponível em: <https://otexts.com/fpp3/>. Acesso em: 11 jun. 2026.
- JAMES, Gareth et al. **An Introduction to Statistical Learning: with Applications in Python**. 2. ed. New York: Springer, 2021. Disponível em: <https://www.statlearning.com/>. Acesso em: 11 jun. 2026.
- SERVIÇO BRASILEIRO DE APOIO ÀS MICRO E PEQUENAS EMPRESAS (SEBRAE). **Restaurantes e similares: emprego e empresas**. Observatório Setorial Territorial, [s.d.]. Disponível em: <https://observatorio.sebrae.com.br/profile/industry/restaurantes-e-similares>. Acesso em: 9 jun. 2026.
- SERVIÇO BRASILEIRO DE APOIO ÀS MICRO E PEQUENAS EMPRESAS (SEBRAE). **Sobrevivência das empresas mercantis brasileiras (2020–2024): relatório técnico**. Brasília: Sebrae, 28 fev. 2025. Disponível em: <https://inteligencia.sebraemg.com.br>. Acesso em: 9 jun. 2026.
- SLACK, Nigel; BRANDON-JONES, Alistair; JOHNSTON, Robert. **Administração da produção**. 8. ed. São Paulo: Atlas, 2018.
- VIANA, Flavia De Siqueira. **Por que ter um restaurante é um negócio tão desafiador?**, Comunidade Sebrae, 14 out. 2024. Disponível em: <https://sebraepr.com.br/comunidade/artigo/por-que-ter-um-restaurante-e-um-negocio-tao-desafiador>. Acesso em: 9 jun. 2026.